

Laboratorio di Programmazione

Compito d'esame per l'appello del 24/02/2022

Una [time series](#) (univariata) è una sequenza di coppie di valori ordinate temporalmente, dove il primo elemento della coppia corrisponde al tempo, mentre il secondo è il valore di una qualche quantità atta a descrivere un certo fenomeno.

Il file [data.csv](#) contiene la time series del numero totale mensile in migliaia di passeggeri su linee aeree internazionali, da Gennaio 1949 a Dicembre 1960. Il primo elemento di ogni riga rappresenta la data ed è in formato Anno-Mese. Il dato si presenta così:

```
date,passengers
1949-01,112
1949-02,118
1949-03,132
...
```

ovvero, messa sotto forma di tabella per comodità:

date	passengers
1949-01	112
1949-02	118
1949-03	132
...	...

Vogliamo leggere questo tipo di dati e capire se dati due anni consecutivi c'è stata una variazione nel numero di passeggeri tra coppie di mesi quasi uguale, da un'anno all'altro.

In altre parole, vogliamo calcolare la variazione tra ogni coppia di mesi, e paragonarla con la variazione della stessa coppia di mesi dell'anno seguente, valutando se questa variazione è uguale, con una tolleranza di ± 2 .

Per esempio, prendiamo in considerazione i primi due anni (1949 e 1950). Possiamo creare una lista di 12 elementi per ogni anno, dove l'elemento all'indice i corrisponde al numero di passeggeri per il mese $i+1$ in quell'anno (all'indice 0 avremo il valore per il mese 1, Gennaio):

1949: [112,118,132,...]

1950: [115,126,141,...]

Per rispondere alla nostra domanda, iniziamo con il calcolare la differenza per ogni coppia di mesi. Consideriamo solo le coppie ordinate, ovvero Gennaio e Marzo non le consideriamo una coppia. Per esempio, per l'anno 1949 e 1950:

1949: [118-112, 132-118,...] = [6, 14, ...]

1950: [126-115, 141-126,...] = [11, 15, ...]

Dove il numero "6" è il risultato della differenza tra Gennaio e Febbraio, "14" il risultato della differenza tra Febbraio e Marzo, e così via.

Poi, confrontiamo i valori ottenuti per ogni coppia di mesi tra i due anni. In questo esempio, dobbiamo confrontare se 6 e 11 sono simili con una tolleranza di ± 2 (in questo caso no), e procedere con la coppia di mesi seguenti, controllando se 14 e 15 sono simili (ed in questo caso si).

Informazioni sullo svolgimento

Create la classe `CSVTimeSeriesFile`, modificando o estendendo la classe `CSVFile` vista a lezione (oppure scrivendola da zero). La classe deve essere istanziata sul nome del file tramite

la variabile `name` e deve avere un metodo `get_data()` che torni una lista di liste, dove il primo elemento delle liste annidate è la data ed il secondo il numero di passeggeri.

Questa classe si dovrà quindi poter usare così:

```
time_series_file = CSVTimeSeriesFile(name='data.csv')
time_series = time_series_file.get_data()
```

...ed il contenuto della variabile `time_series` tornato dal metodo `get_data()` dovrà essere così strutturato (come lista di liste):

```
[
    ["1949-01", 112],
    ["1949-02", 118],
    ["1949-03", 132],
    ...
]
```

Per rilevare dove c'è stata una variazione nel numero mensile di passeggeri quasi uguale tra coppie di mesi, dovete creare una funzione a sé stante (cioè definita NON nella classe `CSVTimeSeriesFile` ma direttamente nel corpo principale del programma), di nome `detect_similar_monthly_variations`, che avrà come input primario la time series e che verrà usata così:

```
detect_similar_monthly_variations(time_series, years)
```

..e dove `years` è una lista di due elementi corrispondenti ad i due anni consecutivi da valutare, ad esempio: `years = [1949, 1950]`.

La funzione dovrà ritornare (tramite un `return`) una lista di 11 elementi (poiché con 12 mesi ho 11 coppie), dove ogni elemento sarà `True` se la variazione è *simile* tra quella coppia di mesi per i due anni consecutivi o `False` altrimenti, ovvero:

```
[
    False,          # la coppia gennaio-febbraio non ha variazione simile nei due
anni               # la coppia febbraio-marzo ha variazione simile nei due anni
    True,
    ...
]
```

Il file in cui scrivere il vostro codice deve chiamarsi **"esame.py"** e le eccezioni da alzare in caso di input non corretti o casi limite devono essere istanze di una specifica classe `ExamException`, che dovete definire nel codice come segue, senza modifica alcuna (copia-incollate le due righe):

```
class ExamException(Exception):
    pass
```

...e che poi userete come una normale eccezione, ad esempio:

```
raise ExamException('Errore, lista valori vuota')
```

Qualche informazione in più sulle specifiche e qualche suggerimento:

- Dovete tenere in considerazione che possono esserci dei dati mancanti! Nelle misurazioni di un anno, può mancare il numero di passeggeri per uno o più mesi, ma assumiamo di avere almeno una misurazione all'anno.
- I dati nel file CSV sono solo un'esempio: potreste avere anche dati dell'anno scorso, per capirci.
- Come accennato, per un anno potrebbe mancare il numero di passeggeri per uno o più mesi. In questo caso, assumere che la differenza nel numero di passeggeri per questi mesi tra i due anni NON sia mai simile (quindi `False`).
- Attenzione che gli anni presi come input dalla funzione devono essere validi: per esempio se ci interessano gli anni 1950 e 1951, questi devono essere presenti nei dati, altrimenti va alzata un'eccezione.
- I valori che leggete dal file CSV sono da aspettarsi di tipo intero positivo. Un valore non numerico, oppure vuoto o nullo o negativo non deve essere accettato, ma tutto deve procedere comunque senza alzare eccezioni.

- La serie temporale nel file CSV è da considerare sempre ordinata, se per caso ci dovesse essere un timestamp fuori ordine va alzata un'eccezione (dentro la funzione `get_data()`) senza cercare di riordinare la serie. Stesso discorso se c'è un timestamp duplicato: si alza un'eccezione.
- Il file CSV può contenere letteralmente di tutto. Da linee incomplete a pezzi di testo che non c'entrano niente, e ogni errore **salvo quello di un timestamp fuori ordine o duplicato va ignorato** (ovvero, ignoro la riga contenente l'errore e vado a quella dopo). Nota: se riuscite a leggere due valori (data e temperatura) ma c'è un campo di troppo sulla stessa riga, questo non è da considerarsi un'errore e non bisogna ignorare quella riga.
- La classe `CSVTimeSeriesFile` controlla l'esistenza del file solo quando viene chiamato il metodo `get_data()` e, nel caso il file non esista o non sia leggibile, alza un'eccezione.

Informazioni sulla consegna

La consegna dell'esame deve avvenire tassativamente entro l'ora di inizio dell'appello orale, e può avvenire in due modi: allegando lo script `esame.py`, oppure indicando il commit hash da valutare su un repository GitHub, entrambi mandati via mail a stefano.russo@gmail.com, come descritto più in dettaglio sul repository del corso: <https://github.com/sarusso/ProgrammingLab>

Attenzione: se il file non si chiama "esame.py", se le eccezioni alzate in caso di errori non sono di tipo "ExamException" o se le classi ed i metodi non si chiamano come indicato da specifiche, l'esame non potrà essere valutato!

Nota benissimo: il vostro file deve includere SOLO una classe, una funzione ed una eccezione, non deve includere nessun codice "main" o tantomeno chiedere input all'utente.

Se non vi ricordate bene come si usa Git, potete fare riferimento al tutorial dei tutor che è disponibile qui: https://github.com/drOpZ/proglab2021-tutors/blob/master/git_quickstart.md.